

Analyse de l'impact de la température sur la consommation d'électricité

Manel Garmachi

2026-01-21

Contents

Contexte et objectifs clairs	3
Contexte	3
Problématique	3
Objectifs	3
Objectif principal	3
Objectifs spécifiques	3
Spécification des Variables	3
Variable dépendante : Consommation d'électricité	3
Variable explicative : Température moyenne	4
Période d'étude	4
Sources de données	4
Consommation d'électricité	4
Température	4
Importation des données	4
Collecte des données météorologiques	5
Analyse de Données	7
Analyse temporelle de la consommation d'électricité par habitant en Tunisie (2015–2022)	7
Visualisation conjointe : température vs consommation	10
Analyse de corrélation	11
Régression linéaire simple	11
Visualisation du modèle estimé	11
Régression non linéaire (terme quadratique)	12
Comparaison des modèles	13
Modèles de Machine Learning	13
Modèle 1 : Régression Ridge	14
Modèle 2 : Régression Lasso	15
Modèle 3 : Random Forest	15
Comparaison des modèles	16
Analyse finale	17
Conclusion générale	17

Contexte et objectifs clairs

Contexte

La Tunisie connaît une augmentation continue de la demande en électricité, portée par le développement économique, l'urbanisation et l'évolution des modes de consommation. Parallèlement, le pays est soumis à des variations climatiques marquées, notamment des vagues de chaleur estivales, susceptibles d'accentuer la consommation liée à la climatisation. Dans ce contexte, analyser le lien entre la température et la consommation d'électricité est essentiel pour mieux comprendre la dynamique de la demande énergétique et aider à la planification du système électrique.

Problématique

Dans quelle mesure les variations de température influencent-elles la consommation d'électricité en Tunisie sur la période 2015–2022 ?

Objectifs

Objectif principal

L'objectif principal de ce projet est d'analyser l'impact des variations de température sur la consommation d'électricité en Tunisie entre 2015 et 2022, en utilisant des données ouvertes et des outils de data science sous R.

Objectifs spécifiques

- Collecter et préparer deux sources de données pour la période 2015–2022 :
 - la consommation d'électricité par habitant (kWh per capita) issue de la Banque mondiale (fichier CSV)
 - les températures historiques à Tunis obtenues par web scraping à partir d'un site météo.
- Construire un jeu de données consolidé liant, pour chaque année entre 2015 et 2022, la consommation d'électricité et la température moyenne.
- Réaliser une analyse exploratoire des tendances de la consommation d'électricité et de la température sur la période étudiée.
- Modéliser la relation entre les deux variables principales (consommation d'électricité et température moyenne) à l'aide de modèles de régression sous R.
- Interpréter les résultats obtenus et discuter leurs implications pour la gestion de la demande énergétique en Tunisie.

Spécification des Variables

Variable dépendante : Consommation d'électricité

La variable dépendante de cette étude est la consommation d'électricité par habitant en Tunisie, mesurée par l'indicateur *Electric power consumption (kWh per capita)* fourni par la Banque mondiale. Les données annuelles sont extraites sous forme de fichier CSV puis filtrées pour la période 2015–2022. Chaque valeur représente la quantité moyenne d'électricité consommée par habitant au cours d'une année donnée.

Variable explicative : Température moyenne

La variable explicative principale est la température moyenne annuelle, obtenue à partir de données météorologiques historiques pour la ville de Tunis recueillies par web scraping depuis un site de météo.

Les données journalières ou mensuelles sont d'abord extraites au format tableau (HTML), puis agrégées pour calculer, pour chaque année de 2015 à 2022, une température moyenne annuelle.

Cette température moyenne est ensuite utilisée pour expliquer la variation de la consommation d'électricité.

Période d'étude

L'analyse est menée sur la période 2015–2022, ce qui permet de disposer d'un horizon temporel récent tout en tenant compte de plusieurs années de variations climatiques et de consommation.

Sources de données

Cette étude repose sur deux principales sources de données.

Consommation d'électricité

La première source concerne la consommation d'électricité par habitant en Tunisie. Les données sont issues de la base de données de la **Banque mondiale**, à travers l'indicateur *Electric power consumption (kWh per capita)*.

Les données sont téléchargées au format **CSV**, puis filtrées afin de conserver uniquement la période allant de **2015 à 2022**.

Température

La deuxième source concerne la température. Les données de température historique pour la ville de **Tunis** sont collectées à partir d'un site de météo en ligne.

Elles sont extraites par **web scraping sous R**, à l'aide du package **rvest**. Les données recueillies sont ensuite agrégées afin de calculer une **température moyenne annuelle** pour chaque année comprise entre **2015 et 2022**.

Importation des données

Au début de notre analyse, nous commençons par intégrer les données essentielles à partir des sources distincts.

```
# Charger le package tidyverse (manipulation et nettoyage des données)
library(tidyverse)

# Lire le fichier CSV de la Banque mondiale
# skip = 4 permet d'ignorer les premières lignes non utiles du fichier
wb_raw <- read.csv("API_EG.USE.ELEC.KH.PC_DS2_en_csv_v2_1880.csv", skip = 4)

# Filtrer les données pour ne garder que la Tunisie
```

```

# Country.Code = "TUN" correspond au code pays de la Tunisie
wb_tunisia <- wb_raw %>%
  filter(Country.Code == "TUN")

# Transformer les colonnes des années en format long
# Les colonnes commencent par "X" (ex : X2015, X2016, ...)
wb_long <- wb_tunisia %>%
  pivot_longer(
    cols = starts_with("X"),          # Sélection des colonnes des années
    names_to = "year",                # Nom de la nouvelle colonne des années
    values_to = "elec_kwh_per_capita" # Nom de la colonne de consommation
  ) %>%
  mutate(
    # Supprimer le "X" devant l'année (X2015 → 2015)
    # puis convertir l'année en entier
    year = as.integer(sub("X", "", year))
  )

# Filtrer les données pour la période d'étude : 2015 à 2022
# et garder uniquement les colonnes utiles
wb_2015_2022 <- wb_long %>%
  filter(year >= 2015, year <= 2022) %>%
  select(year, elec_kwh_per_capita)

# Afficher les données sous forme de tableau propre dans le rapport
knitr::kable(
  wb_2015_2022,
  caption = "Consommation d'électricité par habitant en Tunisie (2015-2022)"
)

```

Table 1: Consommation d'électricité par habitant en Tunisie (2015–2022)

year	elec_kwh_per_capita
2015	1438.925
2016	1442.057
2017	1457.534
2018	1464.789
2019	1533.800
2020	1423.244
2021	1519.593
2022	1595.467

Collecte des données météorologiques

Nous récupérons les températures historiques de Tunis pour la période 2015–2022 à l'aide de web scraping depuis le site timeanddate.com.

```

# Fonction pour extraire la température moyenne mensuelle

```

```

get_month_temp <- function(year, month) {
  url <- paste0(
    "https://www.timeanddate.com/weather/tunisia/tunis/historic?month=",
    month,
    "&year=",
    year
  )

  page <- read_html(url)

  df <- page %>%
    html_element("table#wt-his") %>%
    html_table(fill = TRUE)

  # Renommer les colonnes pour éviter les erreurs

  names(df) <- paste0("V", seq_along(df))

  df_clean <- df %>%
    slice(-1) %>%
    select(temp = V3) %>%      # le 3e colonne = Temp
    mutate(
      temp_f = as.numeric(gsub("[^0-9.-]", "", temp)),
      temp_c = (temp_f - 32)/1.8 # convertir °F en °C
    )

  df_clean %>%
    summarise(temp_mean = mean(temp_c, na.rm = TRUE)) %>%
    mutate(year = year, month = month)
}

# Exemple pour tester janvier 2018

get_month_temp(2018, 1)

```

```

## # A tibble: 1 x 3
##   temp_mean year month
##   <dbl> <dbl> <dbl>
## 1    14.7  2018     1

```

```

# Boucle pour toutes les années et tous les mois

```

```

years <- 2015:2022
months <- 1:12

all_temps <- map_df(years, function(y) {
  map_df(months, function(m) {
    Sys.sleep(1) # petit délai pour ne pas bloquer le site
    get_month_temp(y, m)
  })
})

```

```
# Calculer la température moyenne annuelle

annual_temps <- all_temps %>%
group_by(year) %>%
summarise(annual_temp_mean = mean(temp_mean, na.rm = TRUE)) %>%
ungroup()

# Afficher le tableau

knitr::kable(annual_temps, caption = "Température annuelle moyenne à Tunis (2015-2022)")
```

Table 2: Température annuelle moyenne à Tunis (2015–2022)

year	annual_temp_mean
2015	17.82913
2016	18.04068
2017	17.47645
2018	19.06838
2019	17.28895
2020	18.31971
2021	18.52714
2022	27.75092

```
write.csv(annual_temps, "temperature_annuelle_tunis.csv", row.names = FALSE)
```


Ce tableau présente la température annuelle moyenne estimée à Tunis sur la période 2015–2022, obtenue par web scraping à partir des observations horaires du site timeanddate.com.

Analyse de Données

Analyse temporelle de la consommation d'électricité par habitant en Tunisie (2015–2022)

```
ggplot(wb_2015_2022, aes(x = year, y = elec_kwh_per_capita)) +
geom_line(color = "blue") +
geom_point(color = "blue") +
labs(
title = "Évolution de la consommation d'électricité par habitant en Tunisie (2015-2022)",
x = "Année",
y = "Consommation d'électricité (kWh par habitant)"
) +
theme_minimal()
```

Évolution de la consommation d'électricité par habitant en Tunisie (2015–2022)



```
elec_variation <- wb_2015_2022%>%
  arrange(year) %>%
  mutate(
    diff_abs = elec_kwh_per_capita - lag(elec_kwh_per_capita),
    diff_pct = 100 * diff_abs / lag(elec_kwh_per_capita)
  )


knitr::kable(
  elec_variation,
  digits = 2,
  caption = "Variation annuelle de la consommation d'électricité par habitant en Tunisie (2015-2022)"
)
```

Table 3: Variation annuelle de la consommation d'électricité par habitant en Tunisie (2015–2022)

year	elec_kwh_per_capita	diff_abs	diff_pct
2015	1438.92	NA	NA
2016	1442.06	3.13	0.22
2017	1457.53	15.48	1.07
2018	1464.79	7.26	0.50
2019	1533.80	69.01	4.71
2020	1423.24	-110.56	-7.21
2021	1519.59	96.35	6.77

year	elec_kwh_per_capita	diff_abs	diff_pct
2022	1595.47	75.87	4.99

```
ggplot(filter(elec_variation, !is.na(diff_pct)),
  aes(x = factor(year), y = diff_pct)) +
  geom_col(fill = "steelblue") +
  geom_hline(yintercept = 0, color = "red") +
  labs(
    title = "Variation annuelle de la consommation d'électricité par habitant",
    x = "Année",
    y = "Variation par rapport à l'année précédente (%)"
  ) +
  theme_minimal()
```



Statistiques descriptives

```
# Statistiques descriptives de la consommation d'électricité
summary(wb_2015_2022$elec_kwh_per_capita)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1423   1441   1461   1484   1523   1595
```


```
# Statistiques descriptives de la température annuelle
summary(annual_temps$annual_temp_mean)
```

##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	17.29	17.74	18.18	19.29	18.66	27.75

Visualisation conjointe : température vs consommation

```
# Fusion des deux jeux de données par l'année
energy_climate <- wb_2015_2022 %>%
left_join(annual_temps, by = "year")

# Nuage de points température - consommation
ggplot(energy_climate,
aes(x = annual_temp_mean, y = elec_kwh_per_capita)) +
geom_point(color = "darkorange", size = 3) +
labs(
title = "Relation entre température moyenne et consommation d'électricité",
x = "Température moyenne annuelle (°C)",
y = "Consommation d'électricité (kWh par habitant)"
) +
theme_minimal()
```



Analyse de corrélation

```
# Calcul du coefficient de corrélation de Pearson
correlation <- cor(
  energy_climate$annual_temp_mean,
  energy_climate$elec_kwh_per_capita,
  use = "complete.obs"
)

correlation
```

```
## [1] 0.7250575
```

Régression linéaire simple

```
# Estimation du modèle de régression linéaire
model_linear <- lm(
  elec_kwh_per_capita ~ annual_temp_mean,
  data = energy_climate
)


# Résumé du modèle
summary(model_linear)
```

```
##
## Call:
## lm(formula = elec_kwh_per_capita ~ annual_temp_mean, data = energy_climate)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -49.15 -27.00 -10.65  15.55  74.21
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   1244.722     94.255  13.206 1.16e-05 ***
## annual_temp_mean    12.428       4.819   2.579  0.0418 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 44.21 on 6 degrees of freedom
## Multiple R-squared:  0.5257, Adjusted R-squared:  0.4467
## F-statistic:  6.65 on 1 and 6 DF, p-value: 0.04183
```

Visualisation du modèle estimé

```
# Nuage de points + droite de régression
ggplot(energy_climate,
aes(x = annual_temp_mean, y = elec_kwh_per_capita)) +
geom_point(color = "darkorange", size = 3) +
geom_smooth(method = "lm", se = TRUE, color = "blue") +
labs(
title = "Régression linéaire : impact de la température sur la consommation",
x = "Température moyenne annuelle (°C)",
y = "Consommation d'électricité (kWh par habitant)"
) +
theme_minimal()
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```



Régression non linéaire (terme quadratique)

```
# Modèle avec terme quadratique
model_quad <- lm(
elec_kwh_per_capita ~ annual_temp_mean + I(annual_temp_mean^2),
data = energy_climate
)
```

```
# Résumé du modèle quadratique
summary(model_quad)
```

```
##
## Call:
## lm(formula = elec_kwh_per_capita ~ annual_temp_mean + I(annual_temp_mean^2),
##     data = energy_climate)
##
## Residuals:
##      1      2      3      4      5      6      7      8
## -32.469 -26.059 -19.899   8.920  52.863 -40.944  58.034  -0.446
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    2676.648    1570.126   1.705   0.149
## annual_temp_mean    -119.094     144.031  -0.827   0.446
## I(annual_temp_mean^2)     2.888       3.161   0.914   0.403
##
## Residual standard error: 44.83 on 5 degrees of freedom
## Multiple R-squared:  0.5936, Adjusted R-squared:  0.431
## F-statistic: 3.651 on 2 and 5 DF,  p-value: 0.1053
```

Comparaison des modèles

```
# Comparaison via le R²
summary(model_linear)$r.squared
```

```
## [1] 0.5257084
```

```
summary(model_quad)$r.squared
```

```
## [1] 0.5935667
```

Modèles de Machine Learning

Afin de compléter l'analyse économétrique classique, des modèles de machine learning supervisé ont été estimés pour prédire la consommation d'électricité par habitant à partir de la température moyenne annuelle. L'objectif est de comparer leurs performances prédictives avec celles des modèles de régression traditionnels.

Préparation des données pour le Machine Learning

```
# Fusion des données électricité + température
ml_data <- wb_2015_2022 %>%
  left_join(annual_temps, by = "year") %>%
  mutate(
    temp = annual_temp_mean,      # température moyenne
    temp_sq = annual_temp_mean^2  # température au carré (non-linéarité)
  ) %>%
  select(year, elec_kwh_per_capita, temp, temp_sq) %>%
```

```
na.omit()

# Variable cible
y <- ml_data$elec_kwh_per_capita

# Matrice explicative (2 variables + glmnet OK)
X <- as.matrix(ml_data[, c("temp", "temp_sq")])
```

Modèle 1 : Régression Ridge

La régression Ridge est une méthode de régularisation qui permet de réduire le sur-apprentissage en pénalisant la taille des coefficients.

```
library(glmnet)
```

```
## Loading required package: Matrix

##
## Attaching package: 'Matrix'

## The following objects are masked from 'package:tidyr':
##
##     expand, pack, unpack

## Loaded glmnet 4.1-10
```

```
set.seed(123)

ridge_model <- cv.glmnet(
  x = X,
  y = y,
  alpha = 0      # Ridge
)
```

```
## Warning: Option grouped=FALSE enforced in cv.glmnet, since < 3 observations per
## fold
```

```
# Lambda optimal
ridge_model$lambda.min
```

```
## [1] 7640.355
```

```
# Coefficients du modèle Ridge
coef(ridge_model, s = "lambda.min")
```

```
## 3 x 1 sparse Matrix of class "dgCMatrix"
##           lambda.min
## (Intercept) 1.481950e+03
## temp       8.911918e-02
## temp_sq    1.978963e-03
```

Modèle 2 : Régression Lasso

La régression Lasso permet à la fois la régularisation et la sélection de variables.

```
lasso_model <- cv.glmnet(  
  x = X,  
  y = y,  
  alpha = 1      # Lasso  
)
```

```
## Warning: Option grouped=FALSE enforced in cv.glmnet, since < 3 observations per  
## fold
```

```
# Lambda optimal  
lasso_model$lambda.min
```

```
## [1] 16.08221
```

```
# Coefficients du modèle Lasso  
coef(lasso_model, s = "lambda.min")
```

```
## 3 x 1 sparse Matrix of class "dgCMatrix"  
##           lambda.min  
## (Intercept) 1420.5073523  
## temp        .  
## temp_sq     0.1670935
```

Modèle 3 : Random Forest

Le modèle Random Forest est une méthode non linéaire basée sur des arbres de décision, capable de capturer des relations complexes.

```
library(randomForest)
```

```
## randomForest 4.7-1.2
```

```
## Type rfNews() to see new features/changes/bug fixes.
```

```
##  
## Attaching package: 'randomForest'
```

```
## The following object is masked from 'package:dplyr':  
##  
##      combine
```

```
## The following object is masked from 'package:ggplot2':  
##  
##      margin
```

```

set.seed(123)

rf_model <- randomForest(
  elec_kwh_per_capita ~ temp + temp_sq,
  data = ml_data,
  ntree = 500,
  importance = TRUE
)

# Importance des variables
importance(rf_model)

```

```

##           %IncMSE IncNodePurity
## temp           NaN      9578.542
## temp_sq        NaN      9111.560

```

Comparaison des modèles

```

# Prédiction
pred_ridge <- predict(ridge_model, newx = X, s = "lambda.min")
pred_lasso <- predict(lasso_model, newx = X, s = "lambda.min")
pred_rf <- predict(rf_model, ml_data)

# Fonction RMSE
rmse <- function(y, y_hat) {
  sqrt(mean((y - y_hat)^2))
}

# Calcul des RMSE
rmse_ridge <- rmse(y, pred_ridge)
rmse_lasso <- rmse(y, pred_lasso)
rmse_rf <- rmse(y, pred_rf)

# Résultats
rmse_ridge

```

```
## [1] 55.16765
```

```
rmse_lasso
```

```
## [1] 41.0655
```

```
rmse_rf
```

```
## [1] 27.60767
```


Analyse finale

L'introduction des modèles de machine learning a permis de compléter l'analyse économétrique classique en évaluant la capacité de différentes approches à prédire la consommation d'électricité à partir de la température moyenne annuelle.

Les modèles de régularisation linéaire, notamment la régression Ridge et la régression Lasso, confirment l'existence d'un lien entre la température et la consommation d'électricité. La régression Lasso met particulièrement en évidence l'importance du terme quadratique de la température, ce qui suggère que l'effet de la température sur la consommation n'est pas strictement linéaire.

Le modèle Random Forest présente la meilleure performance prédictive parmi les modèles testés, avec une erreur quadratique moyenne plus faible. Cette supériorité s'explique par sa capacité à capturer des relations non linéaires et complexes entre les variables, ce qui est cohérent avec le comportement réel de la consommation d'électricité lors des périodes de forte chaleur.

Dans l'ensemble, les résultats du machine learning confirment que la température joue un rôle important dans l'évolution de la consommation d'électricité en Tunisie, tout en montrant que les modèles non linéaires offrent une meilleure capacité de prédiction que les modèles linéaires classiques.

Conclusion générale

Ce travail avait pour objectif d'analyser l'impact de la température sur la consommation d'électricité par habitant en Tunisie sur la période 2015–2022, en mobilisant des données ouvertes et des outils de data science sous R.

L'analyse exploratoire a mis en évidence une évolution globalement croissante de la consommation d'électricité, accompagnée de variations de la température moyenne annuelle. Les analyses de corrélation et de régression ont montré l'existence d'une relation positive entre la température et la consommation d'électricité, confirmant que les périodes plus chaudes sont associées à une demande énergétique plus élevée.

Les modèles de machine learning ont permis d'enrichir cette analyse en offrant une meilleure capacité prédictive, notamment grâce à la prise en compte de relations non linéaires. Le modèle Random Forest s'est révélé le plus performant, soulignant l'importance de considérer des approches flexibles pour modéliser la demande électrique dans un contexte de changement climatique.

En conclusion, cette étude montre que la température constitue un facteur explicatif significatif de la consommation d'électricité en Tunisie, bien qu'elle ne soit pas le seul déterminant. Ces résultats peuvent contribuer à une meilleure anticipation de la demande énergétique et à une planification plus efficace du système électrique, en particulier face à l'augmentation attendue des épisodes de chaleur à l'avenir.